

# Lista 1

## Macroeconomia II

Yuri Passuelo – yuripassuelo@usp.br

August 23, 2025

Resolução dos exercícios da primeira lista da disciplinas de Macroeconomia II.

---

### Cálculo do Equity Premium no Brasil

Neste exercício, você utilizará o modelo de Mehra e Prescott (1985) para calcular o Equity Premium no Brasil. Considere os seguintes estados para o crescimento do dividendo:

$$X = \begin{bmatrix} 0.1359 \\ 0.5949 \\ 1.0539 \\ 1.5129 \\ 1.9719 \end{bmatrix}$$

E a seguinte matriz de transição associada ao crescimento do consumo:

$$M = \begin{bmatrix} 0.0300 & 0.3262 & 0.5175 & 0.1224 & 0.0040 \\ 0.0190 & 0.2679 & 0.5420 & 0.1642 & 0.0069 \\ 0.0116 & 0.2131 & 0.5505 & 0.2131 & 0.0116 \\ 0.0069 & 0.1642 & 0.5420 & 0.2679 & 0.0190 \\ 0.0040 & 0.1224 & 0.5175 & 0.3262 & 0.0300 \end{bmatrix}$$

- (a) Apresente a função valor do agente representativo desta economia.
- (b) Apresente a definição de um equilíbrio competitivo recursivo para esta economia.
- (c) Apresente uma solução analítica para os preços do *equity* e de um ativo livre de risco.
- (d) Utilizando os dados dos vetores  $X$  e  $M$ , compute o *Equity Premium* para o Brasil, variando o fator de desconto  $\beta$  e o coeficiente de aversão relativa ao risco  $\sigma$ . Explique os efeitos dessas variáveis sobre o *Equity Premium*.

- (e) Colete dados sobre os retornos dos ativos arriscados e livre de risco no Brasil e compare o Equity Premium dos dados com aqueles computados no item anterior. Você conclui que há um puzzle?
- (f) Simule séries temporais não estacionárias para os preços nesta economia. Comente sobre o comportamento das séries simuladas.

## Solution

Vamos iniciar lembrando o problema básico do Equity Premium, aqui temos:

- Indivíduo tem opção de alocar renda entre consumo e ativos;
  - Ativos disponíveis são:
    1. Arvore  $s$  que gera dividendos  $y$  com taxa de retorno  $x$  e tem preço  $p(x, y)$
    2. Bonds  $B$  que pagam uma unidade de consumo  $c$  ao fim do período e tem preço  $q(x, y)$
- (a) Do problema apresentado podemos construir nosso problema recursivo:

$$V(s, B, x, y) = \max \left\{ u(c) + \beta \sum_x \pi(x', x) V(x', y', B') \right\}$$

Sujeito a restrição:

$$c + p(x, y)s' + q(x, y)B' \leq (p + x)s + B$$

Em resumo opções de gastos são:

1. Consumo  $c$
2. Compra do ativo  $s'$  a preços  $p(x, y)$
3. Compra do ativo  $B'$  a preços  $q(x, y)$

Se quisermos simplificar alguns iténs, assumimos que tanto  $s$  quanto  $B$  pertencem ao que chamaremos de  $w$ , de forma que nosso problema recursivo será:

$$V(w, x, y) = \max \left\{ u(c) + \beta \sum_x V(w', x', y') \right\}$$

- (b) Para essa economia um equilíbrio competitivo é definido como (i) Uma função Valor, (ii)  $V$  funções políticas  $g_c, g_B$  e  $g_s$ ; e (iii) funções preço  $p(x, y)$  e  $q(x, y)$  tais que:

1. Dada funções preço  $p(x, y)$  e  $q(x, y)$  as funções valor  $V$  e políticas  $g_B$ ,  $g_s$  e  $g_c$  resolvem o problema do consumidor
2. Market Clearing:

$$s' = g_s(w, x, y) = 1$$

$$B' = g_B(w, x, y) = 0$$

$$c = y$$

(c) Derivando as soluções, precisamos diferenciar nossa função valor tanto por  $s'$  quanto  $B'$ , começando por  $s'$ :

$$\frac{\partial V(w, x, y)}{\partial s'} = -p(x, y)u'(c) + \beta \sum_x \pi(x', x) \frac{\partial V(w', x', y')}{\partial s'} = 0$$

Usando Benveniste Sheickman para a segunda parte da equação (diferenciação da função valor) temos:

$$\frac{\partial V(w', x', y')}{\partial s'} = (p(x', y') + x')u'(c')$$

Substituindo:

$$\frac{\partial V(w, x, y)}{\partial s'} = -p(x, y)u'(c) + \beta \sum_x \pi(x', x)(p(x', y') + x')u'(c') = 0$$

Remanejando a equação temos:

$$p(x, y)u'(c) = \beta \sum_x \pi(x', x)(p(x', y') + x')u'(c')$$

Isolando  $p(x, y)$ :

$$p(x, y) = \beta \sum_x \pi(x', x)(p(x', y') + x') \frac{u'(c')}{u'(c)}$$

Vamos a duas importantes substituições aqui, a primeira é que como no exemplo original de Mehra e Prescott (1985), nossa utilidade aqui é:

$$u(c) = \frac{c^{1-\sigma}}{1-\sigma}$$

E temos ao mesmo tempo a etapa de Guess, aonde colocamos que os preços  $p(x, y)$  são lineares em relação ao valor do dividendo do ativo  $s$ , portanto:

$$p(x, y) = p_i y$$

Desse modo temos:

$$p_i y = \beta \sum_x \pi(x', x) (p_i y + x') \left(\frac{c'}{c}\right)^{1-\sigma}$$

Outro ponto importante de se relembra do inicio, em equilibrio o individuo iguala seu consumo  $c$  ao valor do dividendo recebido pela arvore, de modo que:

$$\begin{aligned} c &= y \\ c' &= y' = x' y \end{aligned}$$

Portanto:

$$\begin{aligned} p_i y &= \beta \sum_x \pi(x', x) (p_i y' + x') \left(\frac{y'}{y}\right)^{-\sigma} \\ p_i y &= \beta \sum_x \pi(x', x) (p_i x' y + x') \left(\frac{x' y}{y}\right)^{-\sigma} \\ p_i &= \beta \sum_x \pi(x', x) (p_i x' + x') x'^{-\sigma} \\ p_i &= \beta \sum_x \pi(x', x) (p_i + 1) x'^{1-\sigma} \end{aligned}$$

Separando o somatório temos:

$$p_i = \beta \sum_x \pi(x', x) p_i x'^{1-\sigma} + \beta \sum_x \pi(x', x) x'^{1-\sigma}$$

Fazendo uma pequena substituição em relação a índices e somatórios temos:

$$p_i = \beta \sum_{j=1}^N \pi(x_j, x_i) p_i x_j^{1-\sigma} + \beta \sum_{j=1}^N \pi(x_j, x_i) x_j^{1-\sigma}$$

Como temos ao todo  $N$  estados definidos pela nossa cadeia de Markov relacionada aos retornos dos dividendos, podemos montar um sistema de equações e colocamos na forma matricial.

$$\mathbf{A} = \beta \boldsymbol{\pi} \odot \bar{\mathbf{X}}$$

Aonde:

$$\mathbf{X} = \begin{bmatrix} x_1^{1-\sigma} \\ \vdots \\ x_N^{1-\sigma} \end{bmatrix}, \bar{\mathbf{X}} = \begin{bmatrix} \dots & \mathbf{X}^T & \dots \\ & \vdots & \\ \dots & \mathbf{X}^T & \dots \end{bmatrix}$$

Outra matriz importante é:

$$\mathbf{B} = \beta \mathbf{X}^T \boldsymbol{\pi}$$

De modo que tenhamos:

$$\mathbf{p} = \mathbf{p}\mathbf{A} + \mathbf{B}$$

$$\mathbf{p} - \mathbf{p}\mathbf{A} = \mathbf{B}$$

$$\mathbf{p}(\mathbf{I} - \mathbf{A}) = \mathbf{B}$$

$$\mathbf{p} = (\mathbf{I} - \mathbf{A})^{-1} \mathbf{B}$$

Definido o preço de equilíbrio para o ativo  $s'$  vamos ao ativo  $B'$  começando pela sua C.P.O:

$$\frac{\partial V(w, x, y)}{\partial B'} = -q(x, y)u'(c) + \beta \sum_x \pi(x', x) \frac{\partial V(w', x', y')}{\partial B'} = 0$$

Usando Benveniste Scheikman para a diferenciação da função valor no lado direito temos:

$$\frac{\partial V(w', x', y')}{\partial B'} = u'(c')$$

Substituindo na Equação anterior temos:

$$\frac{\partial V(w, x, y)}{\partial B'} = -q(x, y)u'(c) + \beta \sum_x \pi(x', x)u'(c') = 0$$

Logo:

$$q(x, y)u'(c) = \beta \sum_x \pi(x', x)u'(c')$$

Isolando  $q(x, y)$  temos:

$$q(x, y) = \beta \sum_x \pi(x', x) \frac{u'(c')}{u'(c)}$$

Aqui podemos substituir a utilidade marginal dado a parametrização da nossa função utilidade:

$$u(c) = \frac{c^{1-\sigma}}{1-\sigma}$$

Logo:

$$q(x, y) = \beta \sum_x \pi(x', x) \left(\frac{c'}{c}\right)^{-\sigma}$$

Da mesma forma temos que em equilíbrio  $c = y$  e  $c' = y' = x'y$  e portanto:

$$q(x, y) = \beta \sum_x \pi(x', x) \left(\frac{x'y}{y}\right)^{-\sigma}$$

$$q(x, y) = \beta \sum_x \pi(x', x) x'^{-\sigma}$$

Portanto os preços podem ser determinados dessas maneiras, para  $p(x, y)$  resolvendo o sistema de equações, e para  $q(x, y)$  computando o preço.

(d) Vamos ao desenho de um algoritmo em Python para que possamos computar, de acordo com o modelo visto acima.

```
import numpy as np
import matplotlib.pyplot as plt

# Lista 1 - Parametrizacao

X = np.array([ 0.1359,
               0.5949,
               1.0539,
               1.5129,
               1.9719])

pi = np.array([ [0.0300, 0.3262, 0.5175, 0.1224, 0.0040],
                [0.0190, 0.2679, 0.5420, 0.1642, 0.0069],
                [0.0116, 0.2131, 0.5506, 0.2131, 0.0116],
                [0.0069, 0.1642, 0.5420, 0.2679, 0.0190],
                [0.0040, 0.1224, 0.5175, 0.3262, 0.0300] ])

# Funcao para Calculo do Premio de Risco
def risk_pre( beta, sigma, pi=pi, X=X ):

    # Distribui o Invariante
    pi_bar = np.array( np.matrix(pi)**1000 )

    # Tamanho de X
    l_x = len( X )

    # Matrices Formatadas X
    X_s1 = X**(1-sigma)
    X_s2 = X**(-sigma)
```

```

# Matrizes para Calculo (A e B)
# Matriz A
A = beta*np.full( (l_x,l_x), [X_s1] )*pi

# Matriz B
B = beta* ( X_s1.T @ pi )

# Precos da arvore
p = np.linalg.inv( np.identity( l_x ) - A ) @ B

# Retorno da arvore
m_g_p = np.meshgrid( p, p )
R = ( (m_g_p[0] + np.ones( (l_x,l_x))) * np.full( (l_x,l_x), X) -
      m_g_p[1] )/ m_g_p[1]

# Retorno esperado
Re = ( pi.T * R ) @ np.ones( l_x )

# Retorno esperado - Longo Prazo
r_e = np.dot(Re, pi_bar[0] )

# Parte do Bond:
Q = beta * pi @ X_s2

# Retornos Bonds Livres de Risco
r_f = np.sum( ( 1/Q - 1) * pi_bar[0] )

return ( r_e, r_f, r_e-r_f )

# Construindo Grids de Combina es Distintas de \beta e \sigma
beta_grid = np.linspace( 0.1, 1, 100 )
sigm_grid = np.linspace( 0.1, 5, 100 )

# Mesh Grid
bet, sig = np.meshgrid( beta_grid, sigm_grid )

# Combinacoes
comb = np.array( [ [ risk_pre( beta = b, sigma = s) for s in sigm_grid ]
                  for b in beta_grid ] )

# Plots
# Reorganizando Vetores
z_0 = comb[:, :, 0]
z_1 = comb[:, :, 1]
z_2 = comb[:, :, 2]

```




Figure 1: Heatmap Retorno Arvore

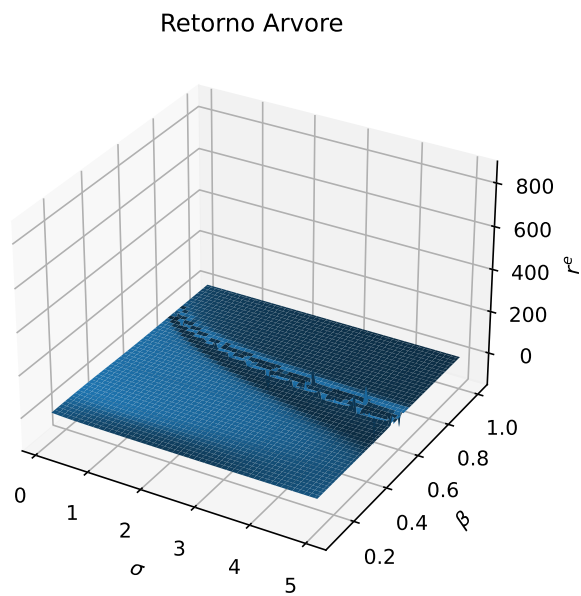


Figure 2: Superfície Retorno Arvore



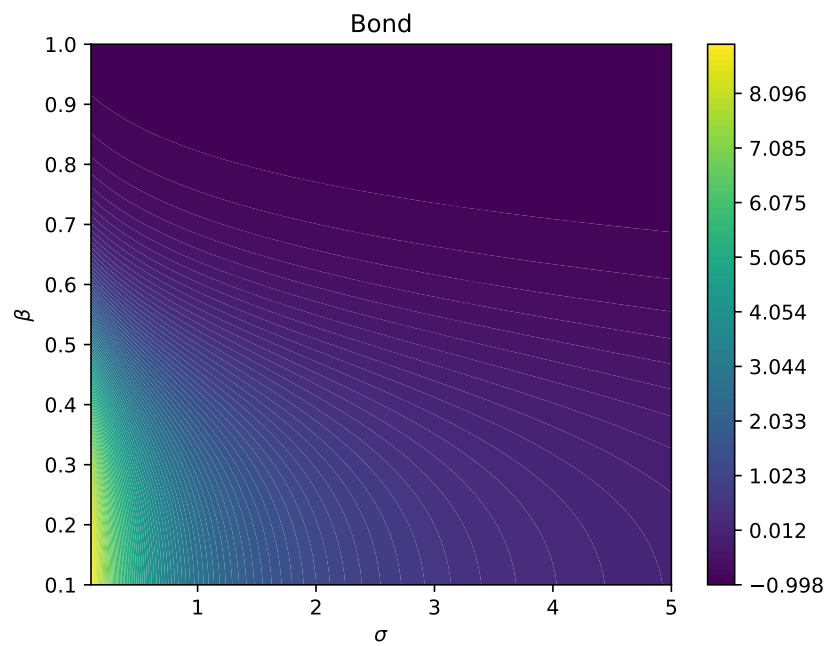


Figure 3: Heatmap Retorno Bond

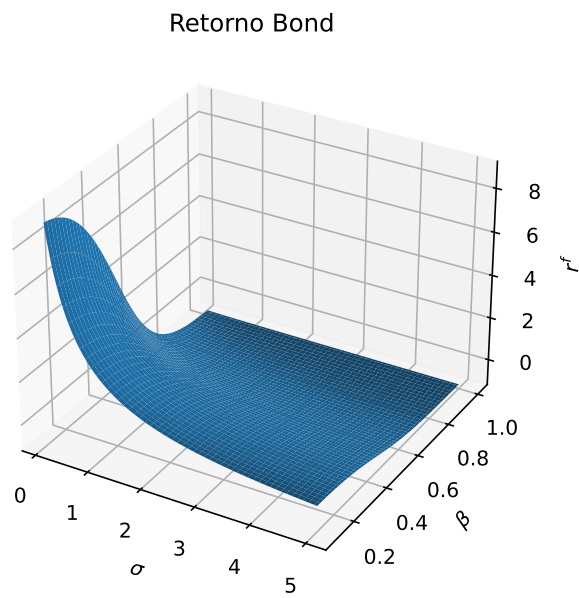


Figure 4: Superficie Retorno Bond

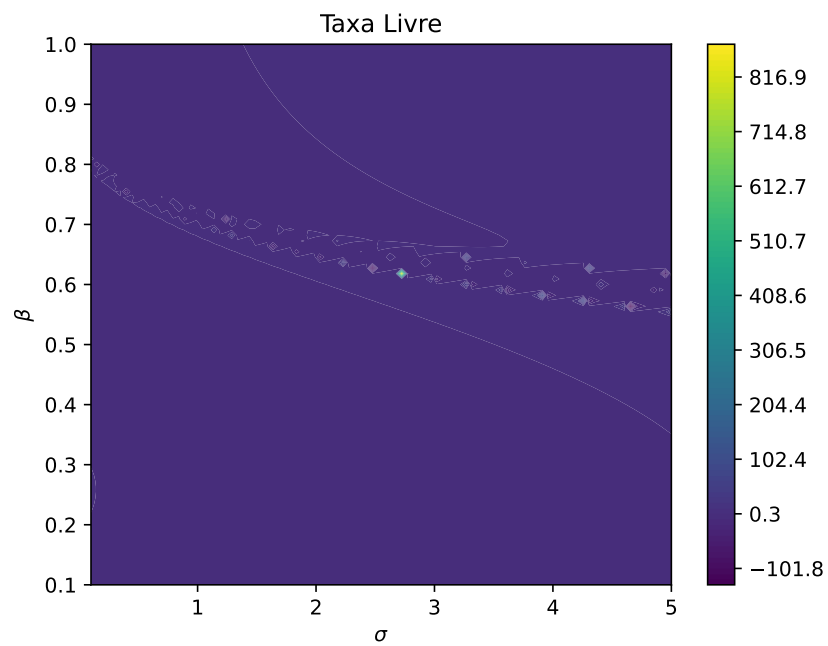


Figure 5: Heatmap Risk Premium

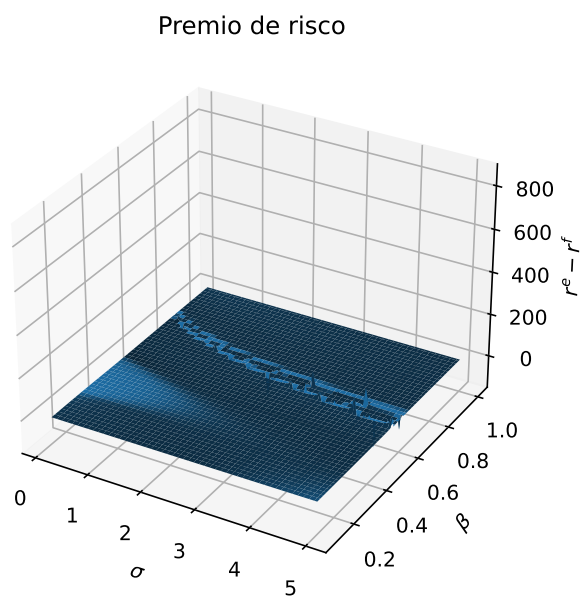


Figure 6: Superfície Risk Premium

Atenção: A matriz  $X^1$  apresenta valores extremos demais o que pode causar retornos estranhos e imprecisos, os gráficos de superfície acima relatam os potenciais problemas, para driblar esses problemas e poder continuar resolvendo os exercícios vamos a baixo propor uma parametrização um pouco diferente:

$$X = [0.93041763, 0.97779789, 1.02517815, 1.0725584, 1.11993866]$$

$$M = \begin{bmatrix} 0.083 & 0.494 & 0.384 & 0.038 & 0 \\ 0.03 & 0.353 & 0.517 & 0.098 & 0.002 \\ 0.009 & 0.206 & 0.57 & 0.206 & 0.009 \\ 0.002 & 0.098 & 0.517 & 0.353 & 0.03 \\ 0 & 0.038 & 0.384 & 0.494 & 0.083 \end{bmatrix}$$

Aqui temos Vetores discretizados e suas respectivas matrizes Markovianas usando os dados de despesas de consumo das famílias dessazonalizadas, a discretização feita por meio do método de Tauchen com 5 pontos e um  $\lambda$  de 7.

Com os resultados corrigidos acima temos uma melhor visão de como cada variável  $\beta$  e  $\sigma$  influência sobre o retorno livre de risco:

- Quanto maior  $\sigma$  ou seja a propensão ao risco maior o premio de risco;
- Quanto menor  $\beta$  ou seja o fator de impaciência, maior o premio de risco;

(e) Para a economia Simulada com os parâmetros de:

- $\beta = 0.99$
- $\sigma = 2.0$

Variáveis	Modelo
$r^e$	4.20%
$r^f$	5.84%
$r^e - r^f$	-1.64%

(f) Vamos agora simular séries para os preços nessa economia, para isso vamos usar a seguinte função para simular uma cadeia de markov:

```
def simulate_markov(M, T, x0=2):
    # P( x' = Proximo | x = Atual )
    states = np.arange(M.shape[0])
    s = np.empty(T, dtype=int)
    s[0] = x0
    for t in range(1, T):
        s[t] = np.random.choice(states, p=M[s[t-1], :])
    return s
```

<sup>1</sup>Aqui apresentamos valores discretizados da variação da série de consumo no Brasil

E vamos setar os preços como:

```
T = 2000
s = simulate_markov(pi, T, x0=2)

# Simulando Cadeia de Markov

# Simula dividendos Y_t (levels) ---
Y = np.empty(T)
Y[0] = 1.0 # n vel inicial
for t in range(1, T):
    Y[t] = X[s[t]] * Y[t-1] # Y_{t} = x_t * Y_{t-1}

# Pre os P_t ---
P = p[s] * Y # p[s] seleciona p_{x_t}

# An lises b sicas
logP = np.log(P)
logY = np.log(Y)
rets = np.diff(logP)
```

Assim nossa simulação fica com a seguinte cara:




Figure 7: Simulações de Preços e Dividendos

As escalas estão em log, pois a discretização que usamos mostra que de 5 pontos nossos retornos são positivos em três, o que mostra uma tendência de crescimento quase que exponencial e por isso temos esse movimento forte de crescimento tanto dos preços quanto dos dividendos.